

O'zbek-tili Hujjat Yordamchisi — yakuniy hisobot

Sanatbek Matlatipov · Tabiiy tilni qayta ishlash (VMQ 425-son) · 2026-07-15

Kaggle: <https://www.kaggle.com/code/sanatbek/notebook1dc482cf6> · Video:

https://drive.google.com/file/d/1ZMdLZ1CSFXgbWoxnGxrBqFX2PsHk_v71/view

Talablarning bajarilishi (qisqacha). Notebook Kaggle'da *Run All* bilan xatosiz bajarildi (GPU T4 va oflayn OFFLINE_FALLBACK rejimlarida tekshirilgan). `DocumentAssistantAgent.run()` 5 ta turli so'rovga javob berdi va 3 xil vosita — `sentiment_classify` (m13), `retrieve_docs` (m14 RAG), `summarize` — chaqirilgani `last_trace()` orqali ko'rsatildi. `SentimentAPI` POST /predict endpointi {sentiment, confidence} formatida javob qaytardi (bo'sh matnga 422). `m15_langchain_agent.py` kapstone moduli Kaggle datasetdan import qilindi, bilimlar bazasi (20 hujjat) `index_kb()` orqali yuklandi.

1. Qaysi modul qurishda eng qiyin bo'ldi va nima uchun?

Eng qiyin modul **m12** — **TransformerSummarizer** bo'ldi. Qiyinchilik uch qatlamda yig'ildi. Birinchidan, encoder-decoder oqimidagi maxsus tokenlar tartibi: decoder kirishi <bos> bilan boshlanib, nishon chiqishi bir pozitsiyaga surilishi, padding esa loss hisobidan chiqarilishi kerak — bitta indeks xatosi model "o'rganayotgandek" ko'rinib, aslida javob nusxalashiga olib keladi. Ikkinchidan, kauzal mask va uchta alohida padding-mask (`src`, `tgt`, `memory`) birgalikda to'g'ri berilishi kerak edi. Uchinchidan, amaliy muhit muammosi: eski PyTorch'da `F.scaled_dot_product_attention` yo'qligi sababli avval uni qo'lda ($\text{softmax}(QK^\top/\sqrt{d_k})V$) yozdim, so'ng PyTorch 2.x li alohida `nlp-kurs` muhitini qurib chiqdim. Bu "kod to'g'ri, muhit noto'g'ri" holatini ajratishni o'rgatdi.

2. Eng yaxshi F1 / aniqlik natijasi qaysi modelda chiqdi?

Eng yuqori natijani **m13** — **fine-tune qilingan distilbert-base-multilingual-cased** berdi: GPU rejimida o'zbek sentiment korpusida **F1 $\approx$ 0.82–0.88**. Taqqoslash uchun:

Model	Modul	Ko'rsatkich	Natija
DistilBERT fine-tune (GPU)	m13	F1	0.82–0.88
TF-IDF + LogReg (oflayn zaxira)	m13	F1	0.72–0.78
Mini-Transformer summarizer	m12	ROUGE-1 F1	kichik korpusda overfit-demo

Asosiy xulosa: oldindan o'qitilgan model ozgina nozik sozlash bilan ham klassik TF-IDF yondashuvdan sezilarli ustun, lekin TF-IDF zaxira yo'li GPU'siz muhitda tizimni to'xtatmaslik uchun amaliy jihatdan zarur bo'lib chiqdi (*graceful degradation*).

3. Kelajakda tizimni qanday yaxshilash mumkin?

(1) RAG hozir ekstraktiv — topilgan parcha javob sifatida qaytadi; uni generativ LLM (masalan, Qwen) bilan boyitib, manbalarga tayangan tabiiy javob shakllantirish. (2) Bilimlar bazasini 20 hujjatdan minglab hujjatga kengaytirib, FAISS indeksini diskda saqlash va yangilash oqimini qo'shish. (3) Qwen asosidagi planner'ni asosiy qilib, parafraz so'rovlarda qoidaviy kalit-so'z usulining xatolarini kamaytirish. (4) O'zbek tiliga mos subword tokenizatsiya (SentencePiece) bilan agglutinatativ qo'shimchalar muammosini yumshatish. (5) `SentimentAPI`ni Docker konteynerida CI/CD bilan joylash va monitoring (P16 amaliyotidagi MLOps oqimi) qo'shish.